



Hábitos de vida y rendimiento académico en adolescentes

Un análisis exploratorio de datos sobre la relación entre sueño, redes sociales y actividad física con el rendimiento académico de adolescentes entre 13 y 19 años.

Curso: DataXperience — Grupo 3
Institución: Universidad EAN, Facultad de Ingeniería
Año: 2026

Integrantes:
Laura V. Virguez Letrado
Simón A. Barrantes Arévalo
Ana S. Chávez Puerta
Nicolás D. Moreno Acevedo

¿De qué trata este proyecto?

Se analizaron **2 500 registros** de adolescentes entre 13 y 19 años para explorar cómo tres hábitos de vida se relacionan con su rendimiento académico. El proceso incluyó diagnóstico de calidad de datos, limpieza, análisis exploratorio, correlaciones de Pearson y un modelo de regresión lineal simple.

Redes sociales

Asociación **negativa fuerte**

$r = -0.863$

Horas de sueño

Asociación **positiva fuerte**

$r = 0.805$

Actividad física

Asociación **positiva débil**

$r = 0.204$

Edad

Asociación **prácticamente nula**

$r = -0.001$

Planteamiento del problema

Pregunta de investigación

¿De qué modo ciertos hábitos se relacionan con el rendimiento académico de los adolescentes entre 13 y 19 años?

Preguntas específicas

- ¿Existe relación entre las horas de sueño y el rendimiento académico?
- ¿Existe relación entre el tiempo diario en redes sociales y el rendimiento académico?
- ¿Existe relación entre la actividad física y el rendimiento académico?
- ¿Cuál hábito presenta la asociación más fuerte?



El análisis es exploratorio y correlacional. No busca establecer causalidad ni emitir recomendaciones médicas.

Fuente y características del dataset

Origen

Dataset *Salud Mental en jóvenes*, publicado en **Kaggle** por el usuario **alfonsecaudelfons**. Archivo: `dataset_salud_mental_Alfons.csv`.

Descargado sin modificaciones previas a la limpieza.

Limitación clave

El dataset carece de ficha técnica detallada sobre la metodología de recolección, lo que impide verificar la representatividad de la muestra.

Composición general

2500

Registros

12

Variables

4

Categóricas

8

Numéricas

Variables principales del proyecto


Variable	Descripción	Rango observado	Papel
horas_diarias_redes_sociales	Horas diarias en redes sociales	1.0 – 8.0 h (media: 4.46)	Hábito principal
horas_sueño	Horas de sueño diarias	4.0 – 9.0 h (media: 6.19)	Hábito principal
actividad_fisica	Nivel de actividad física (escala no documentada)	0.0 – 2.0 (media: 0.99)	Hábito principal
rendimiento_académico	Variable de resultado (escala no documentada)	2.0 – 4.0 (media: 2.89)	Variable objetivo
edad	Edad del encuestado	13 – 19 años (media: 15.98)	Control de población

❏ Las escalas de **rendimiento_académico** y **actividad_fisica** no están documentadas en el archivo fuente; se analizan únicamente sobre los valores observados.

Proceso de limpieza y preparación



Todo el proceso se realizó sobre una copia de trabajo (`df_limpio = df.copy()`), sin modificar el DataFrame original. El diagnóstico confirmó **cero valores nulos y cero duplicados**. La limpieza consistió principalmente en verificación formal; no se encontraron errores reales en los datos.



Corrección en la creación de grupos de hábito

El error detectado

Al crear las variables de grupo con `pd.cut()`, los intervalos abiertos por la izquierda excluían el valor mínimo exacto de cada variable, generando valores faltantes de forma silenciosa:


- **grupo_sueño**: 41 registros excluidos (mínimo = 4.0 h)
- **grupo_redes**: 12 registros excluidos (mínimo = 1.0 h)

La corrección aplicada

Se añadió el parámetro `include_lowest=True` a las tres agrupaciones. Tras la corrección, las tres variables de grupo tienen **cero valores faltantes** y la suma de categorías coincide con las 2 500 filas del dataset.


Distribución de las variables principales

Distribución de edad



Distribución uniforme entre 13 y 19 años. Ninguna edad concentra una proporción desproporcionada.


Distribución de horas de sueño



Media: 6.19 h (DE: 1.02). Gran parte de la muestra duerme por debajo de las 7–9 h recomendadas.


Distribución de redes sociales, actividad física y rendimiento

Redes sociales




Media: 4.46 h/día. Distribución relativamente uniforme entre 1 y 8 h.

Actividad física



Media: 0.99. Escala no documentada; se interpreta como nivel relativo.

Rendimiento académico



Media: 2.89 (DE: 0.56). Distribución aproximadamente simétrica.

❏ No se identificaron valores atípicos en ninguna de las cuatro variables principales según la regla del rango intercuartílico ($1.5 \times \text{IQR}$).

Correlaciones de Pearson con el rendimiento académico





Tabla de resultados (n = 2 500)

Relación	r	Magnitud
Redes sociales → Rendimiento	-0.863	Negativa fuerte
Sueño → Rendimiento	0.805	Positiva fuerte
Actividad física → Rendimiento	0.204	Positiva débil
Edad → Rendimiento	-0.001	Sin asociación

Todos los valores $p < 0.001$, excepto edad ($p = 0.953$). Con $n = 2\,500$, incluso correlaciones débiles pueden ser estadísticamente significativas; la interpretación se basa en la **magnitud de r**.


Dispersogramas: sueño y redes sociales

Sueño vs. Rendimiento ($r = 0.805$)



A mayor número de horas de sueño, mayor rendimiento académico reportado.

Redes sociales vs. Rendimiento ($r = -0.863$)



La asociación más fuerte del estudio: a mayor uso de redes, menor rendimiento.


Comparación por grupos de hábito

Las variables de grupo (Bajo / Medio / Alto) confirman el mismo orden de importancia hallado en las correlaciones.

Hábito	Grupo Bajo	Grupo Medio	Grupo Alto	Diferencia Alto–Bajo
Horas de sueño	2.46 (n=1119)	3.06 (n=845)	3.53 (n=536)	+1.07
Uso de redes sociales	3.49 (n=740)	2.86 (n=1093)	2.28 (n=667)	-1.21
Actividad física	2.77 (n=973)	2.90 (n=727)	3.02 (n=800)	+0.25

 Este es un patrón descriptivo dentro de la muestra. No implica que cambiar de grupo produzca ese cambio de rendimiento en un individuo en particular.

Regresión lineal simple: redes sociales → rendimiento



Ecuación del modelo

$$\text{rendimiento_académico} = 3.9578 + (-0.2393) \times \text{horas_diarias_redes_sociales}$$

Parámetro	Valor
Pendiente	-0.2393
Intercepto	3.9578
R ²	0.7441
MAE	0.2251
Error estándar (pendiente)	0.0028

Por cada hora adicional de uso diario de redes sociales, el rendimiento predicho disminuye **0.2393 unidades**. Se eligió este predictor por tener el mayor $|r|$ (0.863 vs. 0.805 del sueño).

Hallazgos principales y recomendaciones

Conclusiones

1 Redes sociales: asociación más fuerte

$r = -0.863$: a mayor uso diario, menor rendimiento académico.

2 Sueño: segunda asociación más fuerte

$r = 0.805$: a más horas de sueño, mayor rendimiento.

3 Actividad física: asociación débil

$r = 0.204$: positiva pero considerablemente menor.

Recomendaciones

- Priorizar intervenciones en **redes sociales y sueño**, que mostraron las asociaciones más fuertes.
- Validar con estudios **longitudinales** antes de tratar los resultados como relaciones causales.
- Usar datasets con **ficha técnica completa** y escalas documentadas en investigaciones futuras.
- Explorar variables adicionales (estrés, ansiedad) e incorporar **separación entrenamiento/prueba** en el modelo.

Limitaciones del estudio y referencias

Limitaciones principales

- Análisis transversal y correlacional: no permite establecer causalidad.
- Escalas de `rendimiento_académico` y `actividad_fisica` no documentadas en el archivo fuente.
- Modelo simple (un predictor); no incorpora interacciones entre hábitos ni variables como estrés o ansiedad.
- El R^2 reportado es **dentro de muestra**; no debe interpretarse como desempeño predictivo fuera de muestra.
- Sin ficha técnica de recolección: no es posible verificar la representatividad de la muestra.

Referencias

alfonselcaudelfons. (s.f.). *Salud Mental en jóvenes* [Conjunto de datos]. Kaggle. kaggle.com/datasets/alfonselcaudelfons/salud-mentan-en-jovenes

Universidad EAN, DataXperience. (2026). *Clase 05: Carga de datos y primera limpieza*. Universidad EAN.

Universidad EAN, DataXperience. (2026). *Clase 06: Limpieza 2 y visualización*. Universidad EAN.

Universidad EAN, DataXperience. (2026). *Caja de herramientas: Cargue, limpieza y EDA*. Universidad EAN.

Universidad EAN, DataXperience. (2026). *Clase 09: Estadística descriptiva y distribuciones*. Universidad EAN.

Universidad EAN, DataXperience. (2026). *Clase 12: Taller de buenas gráficas*. Universidad EAN.