

UNIVERSIDAD EAN
Facultad de Ingeniería

Curso DataXperience — Grupo 3

Relación entre los hábitos de vida y el rendimiento académico de adolescentes entre 13 y 19 años: un análisis exploratorio de datos

Integrantes:

Laura V. Virguez Letrado
Simón A. Barrantes Arévalo
Ana S. Chávez Puerta
Nicolás D. Moreno Acevedo

Bogotá D. C., Colombia
2026

Resumen

Este informe presenta un análisis exploratorio de datos sobre la relación entre tres hábitos de vida — horas de sueño, uso diario de redes sociales y actividad física — y el rendimiento académico de adolescentes entre 13 y 19 años, a partir de un conjunto de datos de 2500 registros y 12 variables obtenido de Kaggle. El proceso contiene diagnóstico y validación de calidad de los datos, limpieza, análisis exploratorio, cálculo de correlaciones de Pearson y ajuste de un modelo de regresión lineal simple. Los resultados muestran una asociación negativa fuerte entre el uso diario de redes sociales y el rendimiento académico ($r = -0.863$), una asociación positiva fuerte entre las horas de sueño y el rendimiento académico ($r = 0.805$), y una asociación positiva pero considerablemente más débil entre la actividad física y el rendimiento académico ($r = 0.204$). La edad no mostró una asociación relevante con el rendimiento académico ($r = -0.001$).

Palabras clave

Hábitos de vida, rendimiento académico, adolescentes, análisis exploratorio de datos, redes sociales, sueño, actividad física, correlación de Pearson.

1. Introducción

Los adolescentes distribuyen su tiempo diario entre distintas actividades, como dormir, usar redes sociales, realizar actividad física y cumplir con sus responsabilidades académicas. Aunque es común pensar que estos hábitos pueden estar relacionados con el rendimiento escolar, no siempre es fácil saber, solo con la observación diaria, qué tan fuerte es esta relación y de qué manera se presenta.

El presente trabajo, aborda esta pregunta mediante un análisis exploratorio de datos (EDA) sobre un conjunto de datos de adolescentes que incluye información de hábitos de sueño, uso de redes sociales, actividad física y rendimiento académico, entre otras variables. El informe documenta de manera ordenada el proceso seguido: desde la obtención y comprensión de los datos, pasando por su limpieza y preparación, hasta el análisis estadístico, el modelamiento y las conclusiones obtenidas.

2. Planteamiento del problema

2.1 Contexto del problema

El tiempo que tiene un adolescente es limitado y debe dividirse entre dormir, estudiar, usar dispositivos y redes sociales, hacer actividad física y realizar otras actividades del día a día. Entender cómo estos hábitos pueden relacionarse con el rendimiento académico puede ser útil para estudiantes, familias e instituciones educativas. Sin embargo, este análisis no busca dar recomendaciones médicas ni afirmar que un hábito sea la causa directa del rendimiento académico.

2.2 Pregunta de investigación

¿De qué modo ciertos hábitos se relacionan con el rendimiento académico de los adolescentes entre 13 y 19 años?

De esta pregunta principal se derivan las siguientes preguntas específicas:

- ¿Existe relación entre las horas de sueño y el rendimiento académico?
- ¿Existe relación entre el tiempo diario de uso de redes sociales y el rendimiento académico?
- ¿Existe relación entre la actividad física y el rendimiento académico?
- ¿Cuál de estos hábitos presenta la asociación más fuerte con el rendimiento académico?

2.3 Objetivo general

Analizar exploratoriamente la relación entre determinados hábitos de vida (horas de sueño, uso diario de redes sociales y actividad física) y el rendimiento académico de adolescentes entre 13 y 19 años.

2.4 Objetivos específicos

- Diagnosticar y validar la calidad de los datos disponibles antes de cualquier análisis.
- Realizar un proceso de limpieza y preparación de los datos siguiendo la metodología del curso.
- Explorar la distribución de las variables principales del proyecto mediante estadística descriptiva y visualizaciones.
- Calcular y analizar la asociación entre cada hábito y el rendimiento académico mediante el coeficiente de correlación de Pearson.
- Ajustar y evaluar un modelo de regresión lineal simple con el hábito de mayor asociación como predictor.
- Formular conclusiones y recomendaciones que respeten el carácter exploratorio y correlacional del análisis.

3. Obtención y descripción de los datos

3.1 Fuente de los datos

El conjunto de datos utilizado es `dataset_salud_mental_Alfons.csv`, publicado en la plataforma Kaggle por el usuario `alfonselcaudelfons`, bajo el nombre "Salud Mental en jóvenes", disponible en la URL proporcionada para este proyecto. El archivo fue descargado y utilizado sin modificaciones adicionales a las descritas en la sección de limpieza de este informe.

Código utilizado para importar las librerías y cargar el conjunto de datos:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# El CSV ya viene separado por comas y en codificación UTF-8, por lo que no
# se requieren parametros adicionales de lectura.
df = pd.read_csv("dataset_salud_mental_Alfons.csv")
```

Explicación: Estas instrucciones importan las librerías de Ciencia de Datos utilizadas en todo el proyecto (pandas, numpy, matplotlib, seaborn y scipy.stats) y cargan el archivo CSV original en un DataFrame de pandas, punto de partida de todo el análisis.

3.2 Justificación de la selección del dataset

Este conjunto de datos se eligió porque contiene, para cada persona encuestada, información sobre los hábitos que son importantes para la investigación, como el sueño, el uso de redes sociales y la actividad física, además de los datos sobre el rendimiento académico. Esto evita tener que combinar información de diferentes fuentes.

Sin embargo, el dataset no tiene información detallada sobre cómo se recogieron los datos ni una documentación completa de la metodología utilizada. Esto se considera una limitación y se explicará más adelante en la sección de limitaciones del informe.

3.3 Características generales del conjunto de datos

El conjunto de datos está compuesto por 2500 registros (uno por adolescente encuestado) y 12 columnas. La Tabla 1 resume la composición de las cuatro variables categóricas del dataset.

Código utilizado para el diagnóstico inicial (dimensiones y estadística descriptiva):

```
print("Dimensiones (filas, columnas):", df.shape)
print()
print("Columnas detectadas:")
print(list(df.columns))
print()
print("Primeras 5 filas:")
print(df.head())
```

Explicación: Este fragmento permite confirmar cuántas filas y columnas tiene el dataset, ver el nombre exacto de cada columna y revisar visualmente las primeras filas, como primer acercamiento a la estructura de los datos.

Tabla 1. Distribución de las variables categóricas del dataset (n = 2500)

Variable	Categorías	Frecuencias
género	femenino / masculino	femenino: 1255 · masculino: 1245

Variable	Categorías	Frecuencias
uso_plataforma	Instagram / TikTok / Both / Other	Other: 632 · Both: 628 · Instagram: 627 · TikTok: 613
nivel_interacción_social	bajo / medio / alto	alto: 849 · medio: 841 · bajo: 810
riesgo_depresión	bajo / medio / alto	bajo: 1266 · medio: 650 · alto: 584

Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Código utilizado para obtener el conteo de categorías de las variables de texto:

```
columnas_categoricas = df.select_dtypes(include="object").columns
for columna in columnas_categoricas:
    print(f"--- {columna} ---")
    print(df[columna].value_counts())
    print()
```

Explicación: Esta instrucción identifica automáticamente las columnas de tipo texto y calcula la frecuencia de cada categoría, lo que permitió construir la Tabla 1 y verificar que las categorías fueran consistentes.

La Tabla 2 resume la estadística descriptiva de las ocho variables numéricas del dataset.

Código utilizado para calcular la estadística descriptiva de las variables numéricas:

```
print(df.describe())
```

Explicación: `df.describe()` calcula automáticamente la media, la desviación estándar y los valores mínimo y máximo (entre otras medidas) de cada variable numérica, lo que resume de forma rápida la escala y dispersión de los datos.

Tabla 2. Estadística descriptiva de las variables numéricas (n = 2500)

Variable	Media	Desv. estándar	Mín.	Máx.
edad	15.98	2.00	13	19
horas_diarias_redes_sociales	4.46	2.02	1.0	8.0
horas_sueño	6.19	1.02	4.0	9.0
tiempo_pantalla_antes_dormir	1.71	0.72	0.5	3.0
rendimiento_académico	2.89	0.56	2.0	4.0
actividad_física	0.99	0.59	0.0	2.0
nivel_estrés	5.60	3.04	1	10
nivel_ansiedad	5.16	3.00	1	10

Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv. Valores calculados mediante `df.describe()` sobre los datos originales.

3.4 Comprensión de las variables

La Tabla 3 presenta el diccionario completo de las 12 variables del dataset. Para `rendimiento_académico` y `actividad_física` no se documenta una unidad o escala específica en el

archivo fuente, por lo que en este informe no se asume que rendimiento_académico corresponda a un GPA, un promedio sobre una escala determinada o un porcentaje, ni que actividad_física corresponda a horas o a una escala convencional; ambas se analizan únicamente sobre los valores observados.

Tabla 3. Diccionario de variables del dataset dataset_salud_mental_Alfons.csv

Variable	Descripción	Tipo	Rango observado	Papel en el proyecto	Uso en análisis principal
edad	Edad del encuestado	Cuantitativa discreta (entero, años)	13 a 19	Delimitación de población	Sí (control)
género	Género autorreportado	Cualitativa nominal	2 categorías	Secundaria	No
horas_diarias_redes_sociales	Horas diarias en redes sociales	Cuantitativa continua	1.0 a 8.0	Principal (hábito)	Sí
uso_plataforma	Plataforma más usada	Cualitativa nominal	4 categorías	Secundaria	No
horas_sueño	Horas de sueño diarias	Cuantitativa continua	4.0 a 9.0	Principal (hábito)	Sí
tiempo_pantalla_antes_dormir	Tiempo de pantalla antes de dormir	Cuantitativa continua	0.5 a 3.0	Secundaria	No
rendimiento_académico	Variable de resultado; escala NO documentada	Cuantitativa continua	2.0 a 4.0	Principal (resultado)	Sí
actividad_física	Nivel de actividad física; escala NO documentada	Cuantitativa continua	0.0 a 2.0	Principal (hábito)	Sí
nivel_interacción_social	Interacción social autorreportada	Cualitativa ordinal	3 categorías	Secundaria	No
nivel_estrés	Nivel de estrés autorreportado	Cuantitativa discreta (Likert)	1 a 10	Secundaria	No
nivel_ansiedad	Nivel de ansiedad autorreportado	Cuantitativa discreta (Likert)	1 a 10	Secundaria	No

Variable	Descripción	Tipo	Rango observado	Papel en el proyecto	Uso en análisis principal
riesgo_depresión	Riesgo de depresión autorreportado	Cualitativa ordinal	3 categorías	Secundaria	No

Nota. Elaboración propia a partir del notebook

Proyecto_DataXperience_Habitos_Rendimiento_CORREGIDO.ipynb. Las variables secundarias se conservan en el conjunto de datos y se incluyen en el diagnóstico y la limpieza, pero no se analizan en profundidad en el EDA ni en el modelo, ya que no forman parte de la pregunta de investigación.

4. Limpieza y preparación de los datos

Siguiendo la metodología enseñada en el curso, en ningún momento se modificó directamente el DataFrame original (df). Todo el proceso de limpieza se realizó sobre una copia de trabajo (df_limpio = df.copy()), verificada explícitamente como un objeto independiente del original.

Código utilizado para crear la copia de trabajo:

```
df_limpio = df.copy()
```

Explicación: *df.copy() crea una copia independiente del DataFrame original, de modo que todas las transformaciones de limpieza se apliquen únicamente sobre df_limpio y el DataFrame original (df) quede disponible intacto para comparaciones posteriores.*

4.1 Diagnóstico inicial

Antes de cualquier modificación se realizó un diagnóstico completo del dataset original, siguiendo el orden metodológico del curso: dimensiones (df.shape), muestra de filas (df.head(), df.sample()), tipos de dato (df.info()), valores nulos (df.isna().sum()), filas duplicadas (df.duplicated().sum()), estadística descriptiva (df.describe()) y conteo de categorías (value_counts()) en las cuatro variables de texto. El diagnóstico confirmó 2500 filas y 12 columnas, sin valores nulos y sin filas completamente duplicadas.

Código utilizado para el diagnóstico completo del dataset original:

```
print("Dimensiones (filas, columnas):", df.shape)
```

```
print(df.sample(5, random_state=1))
```

```
df.info()
```

```
print("Valores nulos por columna:")
print(df.isnull().sum())
```

```
print("Filas completamente duplicadas:", df.duplicated().sum())
```

Explicación: Estas instrucciones verifican, en orden, el tamaño del dataset, una muestra aleatoria de filas, los tipos de dato de cada columna, la cantidad de valores nulos por columna y la cantidad de filas completamente duplicadas. En conjunto constituyen el diagnóstico inicial antes de aplicar cualquier transformación.

4.2 Validación de calidad más allá de nulos y duplicados

La ausencia de valores nulos y de filas duplicadas no equivale, por sí sola, a que los datos sean de buena calidad: un valor puede estar presente, no estar duplicado, y aun así ser físicamente o lógicamente imposible. Por esta razón, después del diagnóstico inicial se realizó una validación explícita de plausibilidad sobre las variables numéricas, con reglas justificadas por el significado de cada variable (por ejemplo, que la edad esté dentro del rango de la población de estudio de 13 a 19 años, o que ninguna variable de horas sea negativa ni supere las 24 horas de un día). Esta validación no encontró valores lógicamente imposibles en ninguna de las variables revisadas. El código y los resultados de esta validación se presentan en la sección 4.7.

4.3 Normalización de nombres de columnas

Se verificó que los nombres de las 12 columnas ya estaban en minúscula, sin espacios adicionales y con guión bajo como separador, por lo que no fue necesario aplicar ninguna transformación adicional sobre los encabezados.

Código utilizado para verificar la normalización de los nombres de columna:

```
columnas_originales = list(df_limpio.columns)
df_limpio.columns = df_limpio.columns.str.strip().str.lower()
print("Columnas antes :", columnas_originales)
print("Columnas despues:", list(df_limpio.columns))
print("Se modificaron nombres de columna:", columnas_originales != list(df_limpio.columns))
```

Explicación: Esta instrucción normaliza los nombres de columna a minúsculas y sin espacios, y compara la lista de columnas antes y después para confirmar de forma objetiva si hubo algún cambio. El resultado `False` confirma que los encabezados ya cumplían el formato esperado.

4.4 Eliminación de duplicados exactos

Se aplicó `drop_duplicates()` sobre `df_limpio`. El número de filas antes y después de esta operación fue el mismo (2500), confirmando que no existían filas completamente duplicadas.

Código utilizado para eliminar filas duplicadas:

```

filas_antes = len(df_limpio)
df_limpio = df_limpio.drop_duplicates()
filas_despues = len(df_limpio)
print("Filas antes:", filas_antes)
print("Filas despues:", filas_despues)
print("Filas eliminadas por duplicado:", filas_antes - filas_despues)

```

Explicación: `drop_duplicates()` elimina las filas completamente duplicadas del `DataFrame`. Comparar la cantidad de filas antes y después permite confirmar cuántos registros, si los hubiera, fueron eliminados.

4.5 Tratamiento de espacios en variables de texto

Se aplicó `.str.strip()` a las cuatro columnas de texto (género, uso_plataforma, nivel_interacción_social, riesgo_depresión). La comparación entre los valores antes y después de esta operación mostró que ninguna columna tenía espacios adicionales al inicio o al final de sus categorías.

Código utilizado para eliminar espacios adicionales en las variables de texto:

```

columnas_texto = df_limpio.select_dtypes(include="object").columns
cambios_por_columna = {}
for columna in columnas_texto:
    valores_antes = df_limpio[columna].copy()
    df_limpio[columna] = df_limpio[columna].str.strip()
    cambios_por_columna[columna] = (valores_antes != df_limpio[columna]).sum()
print("Valores modificados por columna al quitar espacios:")
print(cambios_por_columna)

```

Explicación: `.str.strip()` elimina espacios en blanco al inicio y al final de cada valor de texto. Contar cuántos valores cambiaron antes y después de la operación permite comprobar, de forma objetiva, si existían espacios adicionales en los datos originales.

4.6 Homogeneización de categorías equivalentes

Además de inspeccionar visualmente las categorías únicas de cada variable de texto, se realizó una verificación cuantitativa: se comparó el número de categorías únicas originales contra el número de categorías únicas tras normalizar cada valor (quitando espacios y convirtiendo a minúsculas). En las cuatro variables de texto el número de categorías no cambió al normalizar, lo que demuestra de forma objetiva —y no solo mediante inspección visual— que no existen categorías equivalentes escritas de forma distinta (por ejemplo, "Femenino" y "femenino" como categorías separadas). Por lo tanto, no fue necesario aplicar ningún diccionario de reemplazo de categorías.

Código utilizado para verificar la existencia de categorías equivalentes:

```

for columna in columnas_texto:
    print(f"--- {columna} ---")
    print(sorted(df_limpio[columna].unique()))
    print()

# Verificación cuantitativa: no basta con mirar la lista de categorías a simple
# vista. Se compara el número de categorías únicas contra el número de categorías
# únicas tras normalizar (quitar espacios y pasar a minúsculas). Si coinciden,
# queda demostrado -- y no solo afirmado -- que no existen categorías equivalentes
# escritas de forma distinta (por ejemplo, "Femenino" / "femenino" / "femenino ").
print("Verificación de categorías equivalentes (normalizado vs. original):")
for columna in columnas_texto:
    unicos_originales = df_limpio[columna].nunique()
    unicos_normalizados = df_limpio[columna].str.strip().str.lower().nunique()
    print(f"{columna}: {unicos_originales} categorías originales, "
          f"{unicos_normalizados} tras normalizar -> "
          f"'sin duplicados ocultos' if unicos_originales == unicos_normalizados else 'POSIBLES DUPLICADOS'")

```

Explicación: Este código lista las categorías únicas de cada variable de texto y luego compara la cantidad de categorías antes y después de normalizar (minúsculas y sin espacios). Si el número de categorías no cambia, se demuestra que no hay categorías equivalentes escritas de forma distinta.

4.7 Validación de valores imposibles

Se aplicaron reglas de plausibilidad sobre las variables numéricas: edad dentro de 13-19 años; horas_sueño y horas_diarias_redes_sociales no negativas ni mayores a 24 horas; actividad_física y rendimiento_académico no negativas. Ninguna de las reglas identificó valores imposibles, por lo que no fue necesario convertir ningún valor a valor faltante en este paso.

Código utilizado para la validación de plausibilidad de las variables numéricas:

```

imposibles = {
    "edad fuera de 13-19": ((df_limpio["edad"] < 13) | (df_limpio["edad"] > 19)).sum(),
    "horas_sueño negativas o > 24h": ((df_limpio["horas_sueño"] < 0) | (df_limpio["horas_sueño"] > 24)).sum(),
    "horas_diarias_redes_sociales negativas o > 24h": ((df_limpio["horas_diarias_redes_sociales"] < 0) | (df_limpio["horas_diarias_redes_sociales"] > 24)).sum(),
    "tiempo_pantalla_antes_dormir negativo o > 24h": ((df_limpio["tiempo_pantalla_antes_dormir"] < 0) | (df_limpio["tiempo_pantalla_antes_dormir"] > 24)).sum(),
    "actividad_física negativa": (df_limpio["actividad_física"] < 0).sum(),
    "rendimiento_académico negativo": (df_limpio["rendimiento_académico"] < 0).sum(),
    "nivel_estrés fuera de 1-10": ((df_limpio["nivel_estrés"] < 1) | (df_limpio["nivel_estrés"] > 10)).sum(),
    "nivel_ansiedad fuera de 1-10": ((df_limpio["nivel_ansiedad"] < 1) | (df_limpio["nivel_ansiedad"] > 10)).sum(),
}

for descripcion, cantidad in imposibles.items():
    print(f"{descripcion}: {cantidad}")

print()
print("Verificación puntual del caso mencionado por la profesora (65 horas de sueño):")
print("Máximo real de horas_sueño en el dataset:", df_limpio["horas_sueño"].max())
print("Mínimo real de horas_sueño en el dataset:", df_limpio["horas_sueño"].min())

```

Explicación: Este código define, para cada variable numérica, una regla de plausibilidad basada en el significado real de la variable (por ejemplo, que la edad esté entre 13 y 19 años) y cuenta cuántos registros la incumplen. Un valor puede no estar duplicado ni ser nulo y, aun así, ser físicamente imposible; esta validación detecta ese tipo de error, que el diagnóstico inicial no cubre.

4.8 Tratamiento de valores faltantes

Como consecuencia del punto anterior, df_limpio no presentó valores faltantes adicionales a los ya verificados en el diagnóstico inicial (cero en las 12 columnas), por lo que no se aplicó ninguna estrategia de imputación ni de eliminación de filas.

Código utilizado para verificar valores faltantes en df_limpio:

```
print("Valores faltantes por columna en df_limpio:")
print(df_limpio.isnull().sum())
```

Explicación: Esta instrucción permite identificar la cantidad de valores nulos presentes en cada variable del conjunto de datos, lo que facilita determinar si es necesario aplicar un tratamiento de valores faltantes.

4.9 Verificación posterior a la limpieza

Se comparó el estado de df (original) y df_limpio (copia de trabajo) en dimensiones, valores nulos, duplicados y rangos de las variables principales. La comparación confirmó que df_limpio conserva las mismas 2500 filas, las mismas 12 columnas, cero nulos y cero duplicados, con los mismos rangos de valores que el dataset original. El resultado de esta etapa es que el conjunto de datos ya cumplía con los criterios de calidad revisados, por lo que la limpieza consistió principalmente en la verificación formal de que no eran necesarias correcciones, y no en la corrección de errores reales.

Código utilizado para comparar el DataFrame original y la copia de trabajo:

```
comparacion = pd.DataFrame({
    "df (original)": [df.shape[0], df.shape[1], df.isnull().sum().sum(), df.duplicated().sum()],
    "df_limpio": [df_limpio.shape[0], df_limpio.shape[1], df_limpio.isnull().sum().sum(), df_limpio.duplicated().sum()],
}, index=["filas", "columnas", "nulos_totales", "duplicados"])
print(comparacion)

print("Rangos en df (original):")
print(df[["edad", "horas_sueño", "horas_diarias_redes_sociales", "actividad_fisica", "rendimiento_académico"]].agg(["min", "max"]))
print()
print("Rangos en df_limpio:")
print(df_limpio[["edad", "horas_sueño", "horas_diarias_redes_sociales", "actividad_fisica", "rendimiento_académico"]].agg(["min", "max"]))
```

Explicación: Este código construye una tabla comparativa entre el DataFrame original y df_limpio (filas, columnas, nulos y duplicados) y compara además los rangos mínimo y máximo de las variables principales, para verificar formalmente que la limpieza no alteró la integridad de los datos.

4.10 Creación de variables derivadas (grupos de hábito)

Para complementar el análisis de correlación con una comparación por categorías (sección 7), se crearon tres variables de grupo mediante pd.cut(): grupo_sueño (Bajo/Medio/Alto), grupo_redes (Bajo/Medio/Alto) y grupo_actividad (Bajo/Medio/Alto).

Durante la verificación de esta etapa se detectó un error en la construcción de dos de las tres agrupaciones: los límites inferiores de grupo_sueño y grupo_redes no incluían el valor mínimo observado de cada variable, debido a que pd.cut() construye, de forma predeterminada, intervalos abiertos por la izquierda. Como el valor mínimo real de horas_sueño es exactamente 4.0 y el de horas_diarias_redes_sociales es exactamente 1.0, esos registros quedaban fuera de cualquier intervalo y se convertían en valores faltantes de forma silenciosa: 41 registros en grupo_sueño y

12 registros en grupo_redes. La variable grupo_actividad no presentaba este problema porque ya se había construido con el parámetro include_lowest=True.

La corrección aplicada consistió en incluir el parámetro include_lowest=True también en grupo_sueño y grupo_redes. Tras la corrección, se verificó explícitamente que las tres variables de grupo tienen cero valores faltantes y que la suma de los conteos por categoría coincide con el total de 2500 filas del dataset, por lo que ninguna agrupación pierde registros en el análisis por grupos de la sección 7.

Código utilizado para crear las variables de grupo (versión corregida, con include_lowest=True):

```
df_limpio["grupo_sueño"] = pd.cut(
    df_limpio["horas_sueño"], bins=[4, 6, 7, 9], include_lowest=True,
    labels=["Bajo (<6h)", "Medio (6-7h)", "Alto (>7h)"]
)

df_limpio["grupo_redes"] = pd.cut(
    df_limpio["horas_diarias_redes_sociales"], bins=[1, 3, 6, 8], include_lowest=True,
    labels=["Bajo (<=3h)", "Medio (3-6h)", "Alto (>6h)"]
)

df_limpio["grupo_actividad"] = pd.cut(
    df_limpio["actividad_física"], bins=[0, 0.7, 1.3, 2], include_lowest=True,
    labels=["Bajo", "Medio", "Alto"]
)

print(df_limpio[["horas_sueño", "grupo_sueño", "horas_diarias_redes_sociales", "grupo_redes", "actividad_física", "grupo_actividad"]].head())
```

Explicación: *pd.cut()* convierte cada variable numérica de hábito en tres categorías (Bajo, Medio, Alto) según los límites (bins) definidos. El parámetro *include_lowest=True* asegura que el valor mínimo observado de cada variable quede incluido en el primer intervalo, evitando que se pierdan registros por el comportamiento predeterminado de *pd.cut()* (intervalos abiertos por la izquierda).

Código utilizado para verificar que ninguna agrupación pierde registros:

```

print("Conteo por grupo_sueño:")
print(df_limpio["grupo_sueño"].value_counts().sort_index())
print()
print("Conteo por grupo_redes:")
print(df_limpio["grupo_redes"].value_counts().sort_index())
print()
print("Conteo por grupo_actividad:")
print(df_limpio["grupo_actividad"].value_counts().sort_index())

# Verificación explícita de que ninguna agrupación pierde registros: se comprueba que
# la suma de los conteos por grupo sea igual al total de filas, y que no haya valores
# faltantes generados por los límites de los intervalos de pd.cut.
print()
print("Valores faltantes por variable de grupo (deben ser 0):")
print("grupo_sueño:", df_limpio["grupo_sueño"].isna().sum())
print("grupo_redes:", df_limpio["grupo_redes"].isna().sum())
print("grupo_actividad:", df_limpio["grupo_actividad"].isna().sum())
print()
print("Filas totales:", len(df_limpio))
print("Suma grupo_sueño:", df_limpio["grupo_sueño"].value_counts().sum())
print("Suma grupo_redes:", df_limpio["grupo_redes"].value_counts().sum())
print("Suma grupo_actividad:", df_limpio["grupo_actividad"].value_counts().sum())

```


***Explicación:** Este código cuenta los registros por categoría en cada variable de grupo y verifica explícitamente que no haya valores faltantes generados por los límites de los intervalos, confirmando que la corrección aplicada con `include_lowest=True` fue efectiva.*

5. Análisis exploratorio de datos (EDA)

El análisis exploratorio se concentró en las cinco variables principales del proyecto: edad, horas_sueño, horas_diarias_redes_sociales, actividad_física y rendimiento_académico. Las variables secundarias del dataset (género, uso_plataforma, tiempo_pantalla_antes_dormir, nivel_interacción_social, nivel_estrés, nivel_ansiedad y riesgo_depresión) se revisaron en el diagnóstico y la limpieza, pero no se profundizó en su análisis, ya que no forman parte de la pregunta de investigación.

5.1 Distribución de la edad

La muestra cubre las edades de 13 a 19 años de forma relativamente uniforme, sin que ninguna edad concentre una proporción desproporcionada de los registros. Esto respalda el uso de la muestra completa sin necesidad de restringirla a un subrango de edad.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.


Código utilizado para graficar la distribución de la edad:

```
fig, ax = plt.subplots(figsize=(8, 4))
sns.histplot(data=df_limpio, x="edad", discrete=True, ax=ax)
ax.set_title("Distribucion de edad de los encuestados")
ax.set_xlabel("edad (anos)")
ax.set_ylabel("cantidad de adolescentes")
plt.show()
```

Explicación: `sns.histplot()` con `discrete=True` genera un histograma de barras para la variable *edad*, tratando cada año como una categoría independiente, lo que permite observar si la muestra está balanceada entre las edades de 13 a 19 años.

5.2 Distribución de las horas de sueño

La distribución de horas de sueño tiene una media de 6.19 horas (desviación estándar de 1.02), con un rango entre 4.0 y 9.0 horas. Una parte relevante de la muestra duerme por debajo de las 7-9 horas recomendadas usualmente para adolescentes, lo cual es relevante como contexto para la relación analizada en la sección 6.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Código utilizado para graficar la distribución de las horas de sueño:


```
fig, ax = plt.subplots(figsize=(8, 4))
sns.histplot(data=df_limpio, x="horas_sueño", kde=True, ax=ax)
ax.set_title("Distribucion de horas de sueño diarias")
ax.set_xlabel("horas de sueño")
ax.set_ylabel("cantidad de adolescentes")
plt.show()

print("Horas de sueño -- media:", round(df_limpio["horas_sueño"].mean(), 2),
      "| mediana:", round(df_limpio["horas_sueño"].median(), 2),
      "| minimo:", df_limpio["horas_sueño"].min(),
      "| maximo:", df_limpio["horas_sueño"].max())
```

Explicación: El histograma con curva de densidad (`kde=True`) muestra la forma de la distribución de horas de sueño, mientras que el segundo bloque calcula la media, la mediana y los valores extremos, lo que en conjunto describe cuánto y de qué forma duerme la muestra.

5.3 Distribución del uso diario de redes sociales

El uso diario de redes sociales varía ampliamente, entre 1.0 y 8.0 horas, con una media de 4.46 horas (desviación estándar de 2.02). Esta variable es una de las tres variables de hábito central del proyecto.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.


Código utilizado para graficar la distribución del uso diario de redes sociales:

```
fig, ax = plt.subplots(figsize=(8, 4))
sns.histplot(data=df_limpio, x="horas_diarias_redes_sociales", kde=True, ax=ax)
ax.set_title("Distribucion de horas diarias en redes sociales")
ax.set_xlabel("horas diarias en redes sociales")
ax.set_ylabel("cantidad de adolescentes")
plt.show()
```

Explicación: Este histograma con curva de densidad muestra cómo se distribuye el tiempo diario dedicado a redes sociales entre los adolescentes de la muestra, evidenciando una dispersión amplia entre 1 y 8 horas.

5.4 Distribución de la actividad física

La variable actividad_física toma valores entre 0.0 y 2.0 (media de 0.99). Como se indicó en la sección 3.4, el archivo no documenta la unidad exacta de esta escala, por lo que se interpreta únicamente como un nivel relativo de actividad física reportado por cada individuo.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.


Código utilizado para graficar la distribución de la actividad física:

```
fig, ax = plt.subplots(figsize=(8, 4))
sns.histplot(data=df_limpio, x="actividad_física", kde=True, ax=ax)
ax.set_title("Distribucion de actividad física")
ax.set_xlabel("actividad física (escala reportada en el archivo, unidad no documentada)")
ax.set_ylabel("cantidad de adolescentes")
plt.show()
```

Explicación: Este histograma con curva de densidad muestra la forma de la distribución de la variable `actividad_física` sobre la escala observada en el archivo, sin asumir una unidad de medida no documentada.

5.5 Distribución del rendimiento académico

El rendimiento académico se distribuye entre 2.0 y 4.0, con una media de 2.89 (desviación estándar de 0.56) y una forma aproximadamente simétrica. Al igual que con `actividad_física`, la unidad exacta de esta escala no está documentada en el archivo fuente.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Código utilizado para graficar la distribución del rendimiento académico:


```
fig, ax = plt.subplots(figsize=(8, 4))
sns.histplot(data=df_limpio, x="rendimiento_académico", kde=True, ax=ax)
ax.set_title("Distribucion del rendimiento académico")
ax.set_xlabel("rendimiento académico (escala reportada en el archivo, unidad no documentada)")
ax.set_ylabel("cantidad de adolescentes")
plt.show()
```

Explicación: Este histograma con curva de densidad describe la forma de la distribución del rendimiento académico, la variable de resultado principal del proyecto.

5.6 Valores atípicos

Se revisaron valores atípicos en las cuatro variables principales (`horas_sueño`, `horas_diarias_redes_sociales`, `actividad_física` y `rendimiento_académico`) mediante boxplots y el

conteo de atípicos según la regla del rango intercuartílico (1.5 veces el IQR), enseñada en la Caja de Herramientas del curso. No se identificaron valores atípicos relevantes en ninguna de las cuatro variables, lo cual es coherente con los rangos observados en la Tabla 2 y con la ausencia de valores imposibles reportada en la sección 4.7. Es importante distinguir este resultado (ausencia de atípicos estadísticos) de la validación de plausibilidad de la sección 4.7: un valor puede no ser un atípico estadístico y aun así ser imposible, o viceversa; en este dataset no se presentó ninguno de los dos casos.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Código utilizado para generar los boxplots y contar valores atípicos según la regla del IQR:

```
variables_principales = ["horas_sueño", "horas_diarias_redes_sociales", "actividad_física", "rendimiento_académico"]

fig, axes = plt.subplots(1, 4, figsize=(16, 4))
for ax, variable in zip(axes, variables_principales):
    sns.boxplot(data=df_limpio, y=variable, ax=ax)
    ax.set_title(variable)
plt.tight_layout()
plt.show()
```

```
def contar_atipicos_iqr(serie):
    q1, q3 = serie.quantile([0.25, 0.75])
    iqr = q3 - q1
    limite_inferior = q1 - 1.5 * iqr
    limite_superior = q3 + 1.5 * iqr
    return ((serie < limite_inferior) | (serie > limite_superior)).sum()

for variable in variables_principales:
    print(f"{variable}: {contar_atipicos_iqr(df_limpio[variable])} valores atipicos (regla IQR)")
```

Explicación: Los boxplots permiten inspeccionar visualmente la dispersión y los posibles valores extremos de cada variable, mientras que la función `contar_atipicos_iqr()` aplica formalmente la regla del rango intercuartílico ($1.5 \times IQR$) para contar cuántos registros, si los hay, se consideran atípicos en cada variable.

6. Análisis estadístico

Para analizar la asociación entre cada hábito y el rendimiento académico se utilizó el coeficiente de correlación de Pearson (r), calculado con `scipy.stats.pearsonr`. El coeficiente r mide la fuerza y la dirección de una relación lineal entre dos variables continuas, y toma valores entre -1 y 1: valores cercanos a 1 indican una relación lineal positiva fuerte, valores cercanos a -1 indican una relación lineal negativa fuerte, y valores cercanos a 0 indican ausencia de relación lineal. El valor p asociado indica la probabilidad de observar una correlación tan extrema como la calculada si, en realidad, no existiera relación lineal alguna en la población; un valor p pequeño indica que la correlación observada es poco probable que se deba únicamente al azar.

Es importante diferenciar la significancia estadística de la magnitud práctica de una asociación: con un tamaño de muestra grande, como los 2500 registros de este dataset, incluso correlaciones relativamente débiles pueden resultar estadísticamente significativas (valor p muy pequeño). Por esta razón, en este informe la interpretación de cada relación se basa principalmente en la magnitud de r , y no únicamente en si el valor p es menor a un umbral convencional.

Código utilizado para calcular la correlación de Pearson entre cada hábito y el rendimiento académico:

```
variables_habito = ["horas_sueño", "horas_diarias_redes_sociales", "actividad_física"]

fig, ax = plt.subplots(figsize=(6, 5))
matriz_correlacion = df_limpio[variables_habito + ["rendimiento_académico", "edad"]].corr()
sns.heatmap(matriz_correlacion, annot=True, fmt=".2f", cmap="coolwarm", center=0, ax=ax)
ax.set_title("Correlación entre hábitos, edad y rendimiento académico")
plt.show()
```


Explicación: `stats.pearsonr()` calcula el coeficiente de correlación de Pearson (r) y su valor p para cada par de variables. Este bucle calcula la correlación entre cada uno de los tres hábitos y el rendimiento académico, además de la correlación con la edad, que se usa como variable de control.

Tabla 4. Correlación de Pearson entre cada hábito, la edad y el rendimiento académico (n = 2500)

Relación analizada	r	Valor p	Dirección	Magnitud
horas_sueño vs. rendimiento_académico	0.805	< 0.001	Positiva	Fuerte
horas_diarias_redes_sociales vs. rendimiento_académico	-0.863	< 0.001	Negativa	Fuerte
actividad_física vs. rendimiento_académico	0.204	< 0.001	Positiva	Débil
edad vs. rendimiento_académico	-0.001	0.953	Prácticamente nula	Sin asociación relevante


Nota. Elaboración propia a partir de la Etapa 8 del notebook Proyecto_DataXperience_Habitos_Rendimiento_CORREGIDO.ipynb (scipy.stats.pearsonr).

La relación entre horas de sueño y rendimiento académico es positiva y fuerte ($r = 0.805$, $p < 0.001$): en esta muestra, a mayor número de horas de sueño, mayor tiende a ser el rendimiento académico reportado.




Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

La relación entre el uso diario de redes sociales y el rendimiento académico es negativa y fuerte ($r = -0.863$, $p < 0.001$), la más fuerte de las tres relaciones analizadas: a mayor tiempo diario dedicado a redes sociales, menor tiende a ser el rendimiento académico reportado.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

La relación entre la actividad física y el rendimiento académico es positiva pero considerablemente más débil que las dos anteriores ($r = 0.204$, $p < 0.001$). Aunque esta correlación es estadísticamente significativa —principalmente debido al gran tamaño de la muestra—, su magnitud indica una asociación lineal débil entre ambas variables; por lo tanto, no debe interpretarse como una relación de fuerza comparable a la de sueño o redes sociales.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Código utilizado para graficar la relación entre cada hábito y el rendimiento académico:

```
fig, ax = plt.subplots(figsize=(7, 5))
sns.regplot(data=df_limpio, x="actividad_física", y="rendimiento_académico",
            scatter_kws={"alpha": 0.4}, line_kws={"color": "black"}, ax=ax)
ax.set_title("Rendimiento académico según nivel de actividad física")
ax.set_xlabel("actividad física (escala reportada en el archivo)")
ax.set_ylabel("rendimiento académico")
plt.show()
```

Explicación: `sns.regplot()` dibuja un diagrama de dispersión junto con la recta de mejor ajuste, lo que permite visualizar de forma directa la dirección y la fuerza de la relación lineal entre cada hábito y el rendimiento académico, en línea con el coeficiente r calculado.


La relación entre la edad y el rendimiento académico es prácticamente nula ($r = -0.001$, $p = 0.953$, no significativa), lo cual es coherente con el uso de edad únicamente como variable de delimitación de la población de estudio, y no como un hábito de interés central en este proyecto.

Código utilizado para generar el mapa de calor de correlaciones:

```
variables_habito = ["horas_sueño", "horas_diarias_redes_sociales", "actividad_física"]

fig, ax = plt.subplots(figsize=(6, 5))
matriz_correlacion = df_limpio[variables_habito + ["rendimiento_académico", "edad"]].corr()
sns.heatmap(matriz_correlacion, annot=True, fmt=".2f", cmap="coolwarm", center=0, ax=ax)
ax.set_title("Correlación entre hábitos, edad y rendimiento académico")
plt.show()
```

Explicación: `df.corr()` calcula la matriz de correlaciones de Pearson entre todas las variables numéricas seleccionadas, y `sns.heatmap()` la representa visualmente con un código de color, lo que permite comparar de un vistazo la fuerza y dirección de todas las relaciones a la vez.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

7. Relaciones, patrones e insights

Esta sección resume los hallazgos principales del proyecto, complementando las correlaciones de la sección 6 con la comparación de promedios de rendimiento académico entre los grupos de hábito definidos en la sección 4.10 (Tabla 5).

Código utilizado para calcular el rendimiento académico promedio por grupo de hábito:

```
promedio_por_sueño = df_limpio.groupby("grupo_sueño", observed=True)["rendimiento_académico"].mean()
print(promedio_por_sueño)

fig, ax = plt.subplots(figsize=(7, 4.5))
ax.bar(promedio_por_sueño.index.astype(str), promedio_por_sueño.values, color="#4C72B0")
ax.set_title("Rendimiento académico promedio según grupo de horas de sueño")
ax.set_xlabel("grupo de horas de sueño")
ax.set_ylabel("rendimiento académico promedio")
for lado in ["top", "right"]:
    ax.spines[lado].set_visible(False)
plt.show()

rango_sueño = promedio_por_sueño.max() - promedio_por_sueño.min()
rango_redes = promedio_por_redes.max() - promedio_por_redes.min()
rango_actividad = promedio_por_actividad.max() - promedio_por_actividad.min()
print(f"Diferencia entre grupo mas alto y mas bajo -- sueño: {rango_sueño:.2f}")
print(f"Diferencia entre grupo mas alto y mas bajo -- redes sociales: {rango_redes:.2f}")
print(f"Diferencia entre grupo mas alto y mas bajo -- actividad física: {rango_actividad:.2f}")
```

Explicación: `groupby().mean()` calcula el rendimiento académico promedio dentro de cada categoría (Bajo/Medio/Alto) de las variables de grupo creadas en la sección 4.10. Calcular la diferencia entre el grupo más alto y el más bajo permite comparar, en la misma escala del dataset, qué hábito separa más el rendimiento académico entre sus categorías extremas.

Tabla 5. Rendimiento académico promedio por grupo de hábito, tras la corrección de la Etapa 6

Hábito	Grupo Bajo	Grupo Medio	Grupo Alto	Diferencia (Alto – Bajo)
Horas de sueño	2.46 (n = 1119)	3.06 (n = 845)	3.53 (n = 536)	1.07
Uso de redes sociales	3.49 (n = 740)	2.86 (n = 1093)	2.28 (n = 667)	-1.21 (magnitud 1.21)
Actividad física	2.77 (n = 973)	2.90 (n = 727)	3.02 (n = 800)	0.25

Nota. Elaboración propia a partir de la Etapa 9 del notebook (tras la corrección de las agrupaciones descrita en la sección 4.10). Los tres grupos suman las 2500 filas del dataset, sin pérdida de registros.

El patrón por grupos confirma lo encontrado con las correlaciones: la diferencia de rendimiento académico promedio entre el grupo de mayor y menor uso de redes sociales es la más grande de las tres comparaciones (1.21 puntos en la escala observada), seguida de la diferencia entre grupos de sueño (1.07 puntos), mientras que la diferencia entre grupos de actividad física es la más pequeña (0.25 puntos). Este es un patrón descriptivo dentro de esta muestra; no implica que cambiar de grupo produzca, por sí mismo, ese cambio de rendimiento en un individuo en particular.

Hallazgos principales

- El uso diario de redes sociales presentó la asociación más fuerte con el rendimiento académico en esta muestra ($r = -0.863$): a mayor uso diario, menor rendimiento académico reportado.
- Las horas de sueño presentaron también una asociación fuerte, en sentido contrario ($r = 0.805$): a más horas de sueño, mayor rendimiento académico reportado.
- La actividad física presentó una asociación positiva pero considerablemente más débil ($r = 0.204$) que las dos anteriores.
- La edad no mostró una asociación relevante con el rendimiento académico ($r = -0.001$, no significativa), consistente con su papel como variable de delimitación de la población.
- La comparación por grupos confirmó el mismo orden de importancia observado en las correlaciones: redes sociales > horas de sueño > actividad física.
- Se identificó y corrigió un error en la construcción de las agrupaciones de sueño y de redes sociales (sección 4.10), que de no corregirse habría excluido 41 y 12 registros, respectivamente, de la comparación por grupos.

8. Selección del modelo

Se seleccionó un modelo de regresión lineal simple, utilizando horas_diarias_redes_sociales como variable predictora (independiente) y rendimiento_académico como variable objetivo (dependiente).

La elección del predictor se justifica directamente en los resultados del análisis exploratorio de la sección 6: de las tres variables de hábito analizadas, horas_diarias_redes_sociales presentó la magnitud de correlación absoluta más alta con rendimiento_académico ($|r| = 0.863$, frente a 0.805 de horas_sueño y 0.204 de actividad_física). El valor absoluto de r es útil para comparar la fuerza de una asociación lineal independientemente de su dirección (positiva o negativa), lo que permite comparar de forma justa una relación negativa (redes sociales) con una positiva (sueño).

Se eligió un modelo de regresión lineal simple en lugar de un modelo con más variables o técnicas de aprendizaje automático más avanzadas, porque los materiales de clase proporcionados para el curso (Clase 5, Clase 6, Caja de Herramientas, Clase 9 y Clase 12) no explican métodos de modelado más complejos ni la separación de los datos en conjuntos de entrenamiento y prueba. Usar estas técnicas sin estar incluidas en los materiales del curso habría agregado una complejidad innecesaria al proyecto.

9. Aplicación del modelo

El modelo se ajustó mediante `scipy.stats.linregress` sobre las 2500 observaciones de `df_limpio`, obteniendo los siguientes resultados:

Código utilizado para ajustar el modelo de regresión lineal simple:

```

x = df_limpio["horas_diarias_redes_sociales"]
y = df_limpio["rendimiento_académico"]

modelo = stats.linregress(x, y)
print(f"Pendiente (slope): {modelo.slope:.4f}")
print(f"Intercepto: {modelo.intercept:.4f}")
print(f"Coefficiente de correlación (r): {modelo.rvalue:.4f}")
print(f"R al cuadrado: {modelo.rvalue**2:.4f}")
print(f"p-valor: {modelo.pvalue:.4g}")
print(f"Error estándar de la pendiente: {modelo.stderr:.4f}")

```

Explicación: `stats.linregress()` ajusta un modelo de regresión lineal simple entre x (horas_diarias_redes_sociales) e y (rendimiento_académico) y devuelve directamente la pendiente, el intercepto, el coeficiente de correlación, el valor p y el error estándar de la pendiente, que son los parámetros necesarios para definir y evaluar el modelo.

Tabla 6. Resultados del modelo de regresión lineal simple (predictor: horas_diarias_redes_sociales; objetivo: rendimiento_académico)

Parámetro	Valor
Pendiente (slope)	-0.2393
Intercepto	3.9578
Coefficiente de correlación (r)	-0.8626
R ²	0.7441
Valor p	< 0.001
Error estándar de la pendiente	0.0028

Nota. Elaboración propia a partir de la Etapa 10 del notebook Proyecto_DataXperience_Habitos_Rendimiento_CORREGIDO.ipynb.

El modelo ajustado corresponde a la ecuación: $\text{rendimiento_académico} = 3.9578 + (-0.2393) \times \text{horas_diarias_redes_sociales}$. La pendiente negativa confirma la dirección de la relación observada en la sección 6: en el modelo ajustado, por cada hora adicional de uso diario de redes sociales, el rendimiento académico promedio predicho disminuye en 0.2393 unidades (en la escala observada del dataset). El error estándar de la pendiente (0.0028) es considerablemente menor que el valor absoluto de la pendiente, lo que es consistente con el valor p muy pequeño reportado.

Código utilizado para graficar la recta ajustada sobre los datos observados:

```


predicciones = modelo.intercept + modelo.slope * x

fig, ax = plt.subplots(figsize=(7, 5))
ax.scatter(x, y, alpha=0.3, label="datos observados")
orden = x.sort_values().index
ax.plot(x[orden], predicciones[orden], color="black", linewidth=2, label="recta ajustada")
ax.set_title("Modelo de regresión lineal simple: rendimiento académico vs. horas en redes sociales")
ax.set_xlabel("horas diarias en redes sociales")
ax.set_ylabel("rendimiento académico")
ax.legend()
plt.show()

```

Explicación: Este código calcula las predicciones del modelo ($\text{predicciones} = \text{intercepto} + \text{pendiente} \times x$) y las superpone, como una recta, sobre el diagrama de dispersión de los datos

observados, lo que permite verificar visualmente qué tan bien la recta ajustada sigue la tendencia real de los datos.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

La recta ajustada sigue visualmente la tendencia de los datos observados, lo cual es consistente con el valor de r reportado.

10. Evaluación e interpretación del modelo

El modelo se evaluó con dos métricas calculadas directamente a partir de las predicciones sobre la misma muestra utilizada para ajustarlo: el coeficiente de determinación (R^2) y el error absoluto medio (MAE).

Código utilizado para calcular las métricas de evaluación del modelo:

```
residuos = y - predicciones
mae = residuos.abs().mean()

print(f"R al cuadrado: {modelo.rvalue**2:.4f}")
print(f"Error absoluto medio (MAE): {mae:.4f}")
```

Explicación: Los residuos se calculan como la diferencia entre el valor real y el valor predicho por el modelo para cada observación. A partir de ellos se calcula el error absoluto medio (MAE), mientras que el R^2 (coeficiente de determinación) se obtiene directamente como el cuadrado del coeficiente de correlación del modelo.

Tabla 7. Métricas de evaluación del modelo de regresión lineal simple

Métrica	Valor	Interpretación
R^2	0.7441	Proporción de la variación de rendimiento_académico explicada linealmente por horas_diarias_redes_sociales, dentro de esta muestra

Métrica	Valor	Interpretación
MAE	0.2251	Diferencia absoluta promedio entre el rendimiento predicho y el rendimiento real, en la escala observada del dataset


Nota. Elaboración propia a partir de la Etapa 11 del notebook Proyecto_DataXperience_Habitos_Rendimiento_CORREGIDO.ipynb.

Código utilizado para graficar la distribución de los residuos y los residuos contra los valores ajustados:

```
fig, ax = plt.subplots(figsize=(7, 4.5))
sns.histplot(residuos, kde=True, ax=ax)
ax.set_title("Distribución de los residuos del modelo")
ax.set_xlabel("residuo (valor real - valor predicho)")
ax.set_ylabel("cantidad de adolescentes")
plt.show()
```


```
fig, ax = plt.subplots(figsize=(7, 4.5))
ax.scatter(predicciones, residuos, alpha=0.3)
ax.axhline(0, color="black", linewidth=1)
ax.set_title("Residuos vs. valores ajustados")
ax.set_xlabel("valor ajustado (predicho) de rendimiento_académico")
ax.set_ylabel("residuo (valor real - valor predicho)")
plt.show()
```

Explicación: El histograma de residuos permite verificar si los errores del modelo se distribuyen de forma aproximadamente simétrica alrededor de cero, mientras que el gráfico de residuos contra valores ajustados permite detectar patrones (como curvatura o cambios en la dispersión) que indicarían que el modelo lineal simple no es adecuado.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

Los residuos se distribuyen de forma aproximadamente simétrica alrededor de cero, sin un patrón evidente que sugiera un problema grave de ajuste para este modelo simple.



Nota. Elaboración propia a partir de dataset_salud_mental_Alfons.csv.

En esta revisión exploratoria no se observa una curvatura clara ni un aumento constante en la dispersión de los residuos. Esto no significa que los supuestos de la regresión lineal se cumplan perfectamente, pero tampoco se encuentra una señal clara de que el modelo lineal simple no sea adecuado para este análisis.

En general, el modelo logra explicar una parte importante de las diferencias en el rendimiento académico usando una sola variable, lo cual coincide con la fuerte correlación encontrada en la sección 6. Sin embargo, este resultado debe entenderse como una relación entre las variables dentro de esta muestra y no como una relación de causa y efecto. Es decir, el modelo no permite afirmar que reducir las horas de uso de redes sociales hará que un adolescente específico mejore su rendimiento académico en la cantidad indicada por el modelo.

11. Conclusiones

Con base en los resultados obtenidos, y respondiendo directamente a la pregunta de investigación (¿de qué modo ciertos hábitos se relacionan con el rendimiento académico de los adolescentes entre 13 y 19 años?), se concluye lo siguiente:

- Existe una asociación negativa fuerte entre las horas diarias de uso de redes sociales y el rendimiento académico ($r = -0.863$): en esta muestra, a mayor uso diario de redes sociales, menor rendimiento académico reportado.
- Existe una asociación positiva fuerte entre las horas de sueño y el rendimiento académico ($r = 0.805$): a más horas de sueño, mayor rendimiento académico reportado.
- Existe una asociación positiva pero débil entre la actividad física y el rendimiento académico ($r = 0.204$); aunque estadísticamente significativa, su magnitud es considerablemente menor que la de sueño y redes sociales.

- El hábito con la asociación más fuerte con el rendimiento académico, en esta muestra, fue el uso diario de redes sociales, seguido de las horas de sueño y, en tercer lugar y con una asociación considerablemente más débil, la actividad física.
- El modelo de regresión lineal simple, usando las horas en redes sociales como predictor, obtuvo un R^2 de 0.7441 dentro de la muestra analizada, lo que confirma que esta variable, por sí sola, explica una parte considerable de la variación del rendimiento académico observado en los datos.

12. Recomendaciones

- Dado que el uso de redes sociales y las horas de sueño mostraron las asociaciones más fuertes con el rendimiento académico en esta muestra, un seguimiento o una intervención orientada a estos dos hábitos podría ser, desde el punto de vista exploratorio, más prioritaria que una orientada únicamente a la actividad física.
- Cualquier recomendación práctica derivada de este análisis debería validarse con datos adicionales, por ejemplo, mediante un diseño de estudio longitudinal, antes de tratarla como una relación causal o de aplicarla como una intervención dirigida a un adolescente en particular.
- Se recomienda, para investigaciones futuras, utilizar conjuntos de datos con una ficha técnica más completa, que documente la metodología de recolección y las unidades o escalas exactas de variables como rendimiento_académico y actividad_física.
- Se recomienda explorar en trabajos futuros la incorporación de variables adicionales del propio dataset que no se incluyeron en el análisis principal (por ejemplo, nivel de estrés o de ansiedad), así como posibles interacciones entre los hábitos analizados.
- Se recomienda, si se busca evaluar la capacidad predictiva del modelo, incorporar una separación entre datos de entrenamiento y de prueba, técnica que no se abordó en este proyecto por no formar parte del alcance metodológico del curso.

13. Limitaciones

- El análisis es de tipo transversal (un único momento en el tiempo) y correlacional; no permite establecer causalidad en ninguna dirección.
- Las escalas de rendimiento_académico y actividad_física no están documentadas en el archivo fuente, por lo que su interpretación sustantiva en unidades conocidas queda fuera del alcance de este análisis.
- El modelo de regresión utilizado es simple (un único predictor) y no incorpora posibles interacciones entre hábitos ni otras variables del dataset, como nivel de estrés o de ansiedad, que quedaron fuera del análisis principal por definición del alcance del proyecto.
- El modelo se ajustó y se evaluó sobre el mismo conjunto de datos, sin una separación entre entrenamiento y prueba; por lo tanto, el R^2 reportado no debe interpretarse como una medida de desempeño predictivo fuera de muestra.

- El dataset no cuenta con una ficha técnica detallada sobre la metodología de recolección, por lo que no es posible verificar de forma independiente la representatividad de la muestra frente a la población adolescente en general.
- Los resultados corresponden únicamente a la muestra analizada (2500 registros) y no deben generalizarse automáticamente a otras poblaciones de adolescentes sin verificar que las condiciones de recolección sean comparables.

14. Referencias

alfonselcaudelfons. (n.d.). Salud Mentan en jóvenes [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/alfonselcaudelfons/salud-mentan-en-jovenes?resource=download>

Universidad EAN, DataXperience. (2026). Clase 05: Carga de datos y primera limpieza [Material de clase]. Universidad EAN.

Universidad EAN, DataXperience. (2026). Clase 06: Limpieza 2 y visualización [Material de clase]. Universidad EAN.

Universidad EAN, DataXperience. (2026). Caja de herramientas: Cargue, limpieza y EDA [Material de clase]. Universidad EAN.

Universidad EAN, DataXperience. (2026). Clase 09: Estadística descriptiva y distribuciones [Material de clase]. Universidad EAN.

Universidad EAN, DataXperience. (2026). Clase 12: Taller de buenas gráficas [Material de clase]. Universidad EAN.